Análisis de Textos Históricos con Modelos de Lenguaje

Instituto Tecnológico Autónomo de México

Mestría en Ciencia de Datos

Estancia de Investigación

Claudia Ximena Paz Cendejas
214570

Índice

1. Contexto de la orgnaización **3**

2. Introducción **3**

2.1. Descripción del problema 3

2.2. Enfoque de Ciencia de Datos al problema 4

3. Objetivos **5**

4. Datos **6**

4.1. Recopilación de Datos 6

4.2. Tratamiento de los Datos 7

5. Modelo **8**

5.1. Metodología 8

5.2. Desarrollo 9

5.3. Evaluación de Resultados 11

6. Resultados del modelo **11**

6.1. Consulta de la información 11

6.2. Evaluación cualitativa por experto 12

7. Discusión **13**

8. Conclusiones **14**

9. Repositorio **16**

1. Contexto de la orgnaización

El presente proyecto se desarrolla con el grupo de Investigación del Dr. Edgar Francisco Román Rangel, en colaboración con el Dr. Diego Jiménez Badillo del Instituto Nacional de Antropología e Historia (INAH), realizada a través de una estancia de carácter académico.

Esta colaboración busca explorar cómo las herramientas computacionales pueden apoyar el análisis y la organización de textos históricos resguardados por la institución, con la intención de facilitar su estudio y aprovechamiento.

Dentro de este contexto, uno de los retos identificados es que, aunque muchos documentos han sido digitalizados, su contenido no siempre se encuentra estructurado de manera que facilite su análisis automatizado. Esto representa una oportunidad para incorporar enfoques desde la ciencia de datos que permitan organizar y extraer información de forma más eficiente.

2. Introducción

Los textos históricos representan una fuente para el estudio del pasado, ya que permiten reconstruir acontecimientos, comprender dinámicas sociales y analizar procesos políticos y culturales de distintas épocas. A través de estos documentos es posible acceder a perspectivas, contextos y formas de pensamiento propias de cada periodo histórico.

En la actualidad, muchos de estos documentos han sido digitalizados, lo que ha permitido ampliar su acceso y conservación. Sin embargo, su disponibilidad en formato digital no implica necesariamente que su contenido pueda ser explorado o analizado de manera sistemática mediante herramientas computacionales.

2.1. Descripción del problema

Los textos históricos son considerados una parte fundamental para el entendimiento y desarrollo de la sociedad a lo largo de los años. Han contribuido a la comprensión de culturas y de desarrollos políticos y sociales, por lo que se consideran de gran importancia. Sin embargo, dentro de ellos también se encuentra un gran desafío, ya que la información contenida no siempre es clara ni precisa.

Por ejemplo, en algunos documentos se encuentran fragmentos como: “En el pueblo de Xicalapa desta costa de Zapotitlán y su provincia, de la encomienda de Juan Rodríguez Cabrillo de Medrano, a veinte y dos días del mes de noviembre de mil quinientos setenta y nueve años, ante el ilustre señor capitán Juan de Estrada, alcalde mayor desta provincia de Zapotitlán por su majestad...”, donde se mencionan múltiples personas, cargos y lugares sin una estructura explícita que permita identificar fácilmente sus relaciones o roles dentro del texto, además de utilizar formas lingüísticas propias del siglo XVI.

Es importante considerar que documentos fueron creados con el fin de dejar un registro (ya fuera narrativo, administrativo o testimonial) que permitiera conocer y entender el pasado. Sin embargo, en

su elaboración no se contempló su análisis futuro, y mucho menos su análisis computacional, por lo que presentan diversas dificultades estructurales y lingüísticas.

En relación con lo anterior, aparecen problemas en las referencias a personas, lugares e instituciones, las cuales no siempre son explícitas ni consistentes. Asimismo, es común encontrar variaciones ortográficas e incluso menciones que asumen conocimientos propios de la época. Esto provoca que la lectura y comprensión de los textos resulte compleja y que su análisis automatizado sea limitado.

Debido a estas características, la alternativa tradicional ha sido la lectura manual por parte de especialistas como historiadores. Aunque este método resulta viable, ya que permite una compresión profunda del contenido, pero requiere de un gran esfuerzo y tiempo, y más aún cuando hablamos de colecciones grandes de textos como son los textos históricos.

En consecuencia, aunque los textos históricos estén disponibles, su consulta y análisis continuan siendo procesos difíciles y lentos, siendo poco escalables y limitando así su aprovechamiento.

2.2. Enfoque de Ciencia de Datos al problema

Los textos históricos son un conjunto de datos no estructurados con un alto valor de información. Teniendo la ventaja de que los textos se encuentran ya digitalizados, aún nos enfrentamos a su contenido que permanece en lenguaje natural, lo que imposibilita su análisis automatizado.

Es importante tener en cuenta que la información se encuentra a lo largo de todo el texto, por lo que conceptos importantes como personas, lugares, culturas, costumbres, no se encuentran en un lugar específico y se requiere del contexto de todo el texto para entender a lo que se refieren. Adicional a esto, es importante mencionar que una misma palabra puede tener distintos significados y esto solo se puede comprender si tenemos el contexto completo de lo que estamos procesando.

Es por esto que, no podemos realizar simplemente consultas ni extraer información de los textos sin un proceso previo de estructuración de los datos. Se requiere de un proceso que permita extraer información relevante, tener categorías principales que ayuden a un mejor entendimiento del contenido de los textos logrando así que un corpus se convierta en un recurso analizable.

Desde una perspectiva de ciencia de datos, este reto puede formularse como una tarea de extracción de información, particularmente relacionada con el reconocimiento de entidades nombradas (Named Entity Recognition, NER). No obstante, a diferencia de escenarios tradicionales, no se cuenta con un conjunto de datos previamente etiquetado ni con categorías completamente definidas desde el inicio. Esto implica que no es posible entrenar directamente un clasificador supervisado convencional, ya que primero es necesario identificar y delimitar las entidades relevantes dentro del dominio histórico antes de proceder a su modelado.

3. Objetivos

Este proyecto tiene como objetivo desarrollar un modelo que utilice un modelo de lenguaje que permita transformar textos históricos en representaciones vectoriales y estructuradas, facilitando su procesamiento computacional.

De manera específica, se busca formular el problema como una tarea de reconocimiento de entidades nombradas (NER), orientada a la identificación y delimitación de entidades relevantes (como personas, lugares e instituciones) dentro del dominio histórico.

A partir de las representaciones vectoriales generadas, se pretende analizar el contenido semántico de los textos y apoyar el proceso de extracción de información. Dado que no se dispone de datos previamente etiquetados, el modelo deberá permitir el descubrimiento y definición de dichas entidades antes de cualquier esquema de entrenamiento supervisado.

Finalmente, con la información extraída, se busca construir una estructura organizada de información basada en las entidades y relaciones identificadas, que permita realizar consultas y análisis posteriores sobre el corpus histórico.

4. Datos

4.1. Recopilación de Datos

La recopilación de datos se hizo en conjunto con el Dr. Diego Jiménez Badillo, investigador del INAH, quien proporcionó textos históricos digitalizados que conforman el corpus de estudio.

Estos textos corresponden a las *Relaciones Geográficas* de la Nueva España elaboradas en el siglo XVI (1577–1585). Fueron escritos como respuestas a un cuestionario oficial de 50 preguntas distribuido a autoridades locales (gobernadores, virreyes, entre otros) con el objetivo de recopilar información sobre los territorios de la Nueva España [1].

Para este proyecto se utilizó la edición compilada por René Acuña [2], que reúne y transcribe estos documentos en varios volúmenes, con un total de 517 páginas de texto recopilado y transcrito. Otras ediciones relevantes incluyen la recopilación de relaciones correspondientes a la gobernación de Yucatán realizada por Mercedes de la Garza [3].

El subconjunto analizado comprende únicamente las relaciones correspondientes a México y Guatemala, lo que permite trabajar con un corpus coherente en términos geográficos y administrativos. Sin embargo, incluso dentro de este grupo, los documentos presentan una gran variación en extensión, estilo de redacción y nivel de detalle respecto al cuestionario original de 50 preguntas. Esta diversidad dificulta su procesamiento automático y representa un reto para tareas como la identificación de entidades nombradas y la organización estructurada de la información. Los documentos están conformados de la siguiente manera:

	archivo	caracteres	palabras
0	RG_Instrucción.txt	12,270	2,184
1	1_RG_Guatemala_Acuna.txt	480,655	86,796
2	2_RG_Antequera_T1_Acuna.txt	511,907	91,062
3	3_RG_Antequera_T2_Acuna.txt	333,344	58,978
4	4_RG_Tlaxcala_T1_Acuna.txt	611,580	106,324
5	5_RG_Tlaxcala_T2_Acuna.txt	580,202	104,681
6	6_RG_Mexico_T1_Acuna.txt	494,001	87,976
7	7_RG_Mexico_T2_Acuna.txt	329,400	58,366
8	8_RG_Mexico_T3_Acuna.txt	251,422	44,315
9	9_RG_Michoacan_Acuna.txt	576,618	103,541
10	10_RG_Nueva Galicia_Acuna.txt	416,696	75,444
11	11_RGs_Yucatan_T1_DeLaGarza.txt	389,178	70,531
12	12_RGs_Yucatan_T2_DeLaGarza.txt	392,560	70,219
13	14_Suma_Visita_Pueblos_DelPasoYTroncoso.txt	705,164	126,742
TOTAL	—	6,084,997	1,087,159

En el cuestionario se solicitó información detallada sobre diversos aspectos. Comenzando con localización geográfica, distancias, características climáticas, territoriales y de recursos. Y abarcando datos sociales y culturales como lo son lenguas habladas, organización política, costumbres, vestimentas, alimentación, religiones, actividades económicas, etc.

Como consecuencia, tenemos un corpus con documentos muy extensos, sin ninguna estructura y teniendo variación entre las respuestas, desde longitud hasta el tipo de redacción. Es por esto que este corpus es adecuado para la aplicación de modelos que busquen organizar y facilitar la consulta de la información contenida.

4.2. Tratamiento de los Datos

Inicialmente se realizó un preprocesamiento básico de los documentos con el objetivo de facilitar su análisis. En esta etapa se eliminaron elementos no textuales, encabezados repetitivos y caracteres producto de la digitalización, además de normalizar el formato del texto, prácticas comunes en el procesamiento de corpus textuales dentro del área de procesamiento de lenguaje natural [4]. Por ejemplo, se removieron encabezados editoriales, numeración de páginas y otros elementos que no forman parte del contenido original del documento.

Debido a la longitud de los textos y a las limitaciones de procesamiento, los documentos fueron segmentados en fragmentos de menor tamaño, permitiendo su análisis individual sin perder el contexto general. Este tipo de segmentación del texto permite analizar documentos extensos de forma más eficiente y ha sido ampliamente utilizado en tareas de procesamiento de lenguaje natural [5].

En este proceso de segmentación (*chunking*) cada texto fue dividido en fragmentos de tamaño controlado, menor a 1,500 caracteres obteniendo así textos divididos entre 168 y 471 chunks. El factor más importante en esta división es que se busco que cada segmento mantuviera coherencia semántica suficiente para su interpretación individual. Así mismo, se utilizó *overlap* con el objetivo de conservar el contexto entre secciones y evitar la pérdida de referencias mencionadas en distintos párrafos.

Para facilitar el procesamiento automático, los documentos fueron divididos en fragmentos más pequeños o *chunks*.

5. Modelo

Con el fin de sistematizar el análisis de los documentos históricos, se implementó un modelo compuesto por diversas etapas de procesamiento. Este flujo metodológico permite organizar la información extraída y facilitar su posterior análisis. La Figura 1 resume el procedimiento general.

5.1. Metodología

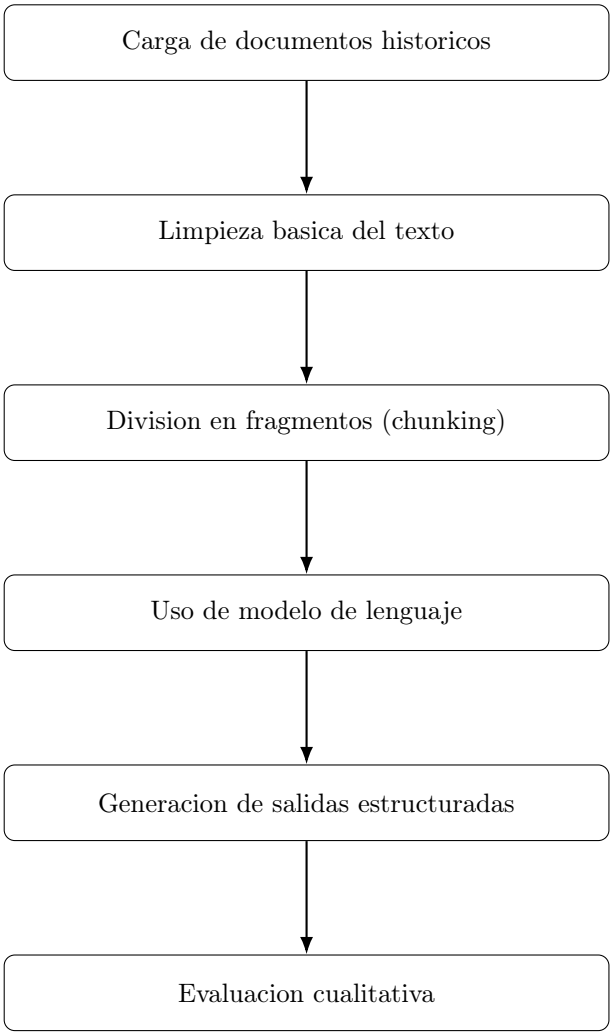

Figura 1: Flujo metodológico del sistema

5.2. Desarrollo

Para lograr organizar e identificar la información relevante dentro de los textos, se empleo un modelo de lenguaje de gran escala (LLM), especifícamente *LLaMa 3.2*. Los modelos de este tipo se basan en arquitecturas *Transformer*, ampliamente utilizadas en tareas de procesamiento de lenguaje natural por su capacidad para modelar relaciones de contexto dentro del texto [6]. Esta solución fue propuesta debido a la información con la que contamos y a que los métodos tradicionales de análisis (como *clustering*) resultaron limitados, pues dependen de formas específicas de escritura, lo que dificulta captar adecuadamente el significado del contenido.

Con estos modelos logramos no solo identificar palabras, sino analizar el contexto y la relación entre ellas, obteniendo así de una manera más sencilla y acertada el significado y relación, siendo particularmente útil en la identificación de una misma palabra con distintos significados, como se presenta muy comúnmente en textos históricos. Por ejemplo, el término "San Pedro"puede referirse tanto a una persona como a un lugar, dependiendo del contexto en el que aparece dentro del texto. Este tipo de análisis es común en procesos de aprendizaje de ontologías a partir de corpus textuales [7].

Estos modelos no solo fueron adecuados por el lenguaje en el que estábamos tratando, sino también nos permitieron trabajar con grandes volúmenes de información de una manera automatizada, logrando que los textos fueran procesados de manera consistente pudiendo comparar entre los distintos archivos con los que contamos y evitando así la pérdida de contexto e información.

Como parte del desarrollo y utilización de los modelos de lenguaje de gran escala, debemos considerar el *prompt* siendo este la guía principal que nos ayuda a una correcta orientación, interpretación y respuesta que buscamos.

Aquí es donde establecemos el contexto de lo que estamos haciendo, el rol que estamos esperando del modelo (qué es y cómo debe actuar) y con más detalle la salida que estamos esperando y así tener una correcta categorización del texto que es lo que estamos buscando.

Es muy importante el detalle que demos al *prompt*, pues muchas veces si nuestras instrucciones no son del todo claras o tienen muy poco detalle, pueden provocar respuestas incompletas o incluso erroneas a lo que estamos buscando. Por lo que en el desarrollo se realizaron distintos experimentos y ajustes en el *prompt*, modificando la forma en que solicitamos la información, en la que el modelo debía actuar, indicando a detalle quién es y que hace y restringiendo el formato y las respuestas que queremos recibir. Fue así que logramos reducir inconsistencias en las respuestas y mejorar la categorización obtenida.

Por lo anterior, el diseño del *prompt* se entiende como una etapa crucial en el modelo, teniendo siempre en mente que el desempeño del modelo no depende únicamente de su capacidad, si no de la claridad y consistencia que proporcionemos.

El *prompt* final utilizado es el siguiente:

```
[...]
```

```
system_prompt = f"""
Eres una asistente experta en análisis semántico de textos coloniales.
Debes seguir una ESPECIFICACIÓN ESTRICTA (Spec-Driven Development).

=== SPECIFICACIÓN ===
- Solo puedes usar las categorías: {", ".join(SPEC["valid_categories"])}
- Solo puedes usar los predicados: {", ".join(SPEC["valid_predicates"])}
- Si un concepto no encaja perfectamente, elige la categoría más cercana.
- No inventes categorías ni predicados.
- Sigue exactamente estos esquemas JSON:

Entidad:
{SPEC["entity_schema"]}

Relación:
{SPEC["relation_schema"]}

Reglas:
1. El JSON generado debe ser **válido**.
2. No escribas texto fuera del JSON.
3. Usa solo contenido del fragmento.
4. Cada entidad debe tener un ID (c1, c2...).
5. La evidencia en relaciones debe ser una cita del fragmento.
6. No dupliques entidades en un mismo chunk.
7. No interpretes más allá del texto.

Tu rol: ejecutar la especificación, no 'ser creativo'.
"""

    user_prompt = f"""
Analiza el siguiente fragmento usando la especificación:
(texto_chunk)

=== TAREA ===
1. Extrae todas las entidades relevantes según las categorías válidas.
2. Extrae todas las relaciones permitidas usando los predicados válidos.
3. Sigue EXACTAMENTE la especificación.
4. Devuelve SOLO el JSON con forma:

[...]

No incluyas comentarios, explicaciones ni texto adicional.
    """
```

5.3. Evaluación de Resultados

Dado que el corpus corresponde a textos históricos, la interpretación de los conceptos obtenidos no puede verificarse únicamente mediante procesos cuantitativos, ya que el sentido de los términos depende de usos lingüísticos propios de la época y de su contexto cultural.

Por esta razón, los resultados generados por los modelos de lenguaje fueron revisados de manera cualitativa: El Dr. Diego Jiménez Badillo evaluó coherencia entre las agrupaciones y relaciones encontradas, así como la interpretación general del contenido, verificando si las categorías producidas por el modelo correspondían con el significado histórico esperado. Con esta revisión fue posible validar si la información organizada por el sistema resultaba comprensible y útil desde una perspectiva disciplinaria.

Por lo que la evaluación combinó el procesamiento automatizado con la validación de un experto de dominio, asegurando que los resultados no solo fueran técnicamente correctos, sino también interpretativamente adecuados para el estudio de los documentos históricos.

6. Resultados del modelo

La información extraída fue organizada en una estructura que nos permitiera conocer las palabras relevantes en los distintos archivos, y ya que se contaba con el contexto y relación, fue posible unificar distintas menciones que hacían referencia a una misma entidad, reduciendo la duplicidad provocada por variaciones ortográficas o denominaciones alternativas.

Asimismo, se establecieron relaciones entre las entidades identificadas, generando una red semántica que representa los vínculos presentes en el corpus. Esta representación permite consultar el contenido de los textos sin necesidad de revisar manualmente cada documento.

6.1. Consulta de la información

Con esta estructura, es posible realizar consultas sobre el corpus, localizar información relevante e identificar conexiones entre elementos históricos. De esta forma, es posible tener una herramienta que nos apoye al análisis de documentos, facilitando la exploración del contenido.

La idea principal de las consultas es que el modelo haya logrado identificar adecuadamente una categoría para las palabras importantes, logrando así tener un diccionario de fácil acceso para cada palabra y logrando identificar temas importantes que ocurran en cada uno de los textos.

La Figura 2 muestra un resumen de las categorías identificadas por el modelo en uno de los textos, así como la cantidad de palabras asociadas a cada una de ellas.

```
=== RESUMEN DE LA ONTOLOGÍA ===

Total de categorías: 40

- actividad_economica: 6 conceptos
- animal: 2 conceptos
- autor: 2 conceptos
- autoridad: 23 conceptos
- cargo: 9 conceptos
- costumbre: 39 conceptos
- cultivo: 6 conceptos
- documento: 6 conceptos
- especie: 2 conceptos
- event_historico: 1 conceptos
- evento_historico: 5 conceptos
- familia: 2 conceptos
- fruta: 10 conceptos
- grupo_social: 17 conceptos
- institucion_colonial: 38 conceptos
- legumbre: 1 conceptos
- lengua: 1 conceptos
- lengua_materna: 2 conceptos
- lenguaje: 1 conceptos
- linaje: 1 conceptos
- lugar: 274 conceptos
```

Figura 2: Ejemplo de categorías obtenidas

6.2. Evaluación cualitativa por experto

A partir de la revisión realizada por el Dr. Diego Jiménez Badillo, se observó que el modelo logra identificar de manera consistente entidades relevantes dentro de los textos, por ejemplo en categorías como lugares y elementos descriptivos. Sin embargo, se identificaron algunos casos de ambigüedad en la clasificación de entidades, asociados a la complejidad del lenguaje histórico.

En general, el experto consideró que los resultados obtenidos son útiles para apoyar el análisis de los documentos, ya que permiten estructurar la información de manera más accesible y mantienen una correspondencia adecuada con el contenido original.

7. Discusión

A pesar de los resultados obtenidos, el sistema presenta ciertas limitaciones. Los modelos de lenguaje pueden generar interpretaciones incorrectas cuando el contexto histórico es ambiguo o cuando la información no es explícita en el texto. En algunos casos, el modelo puede asociar entidades de manera errónea o inferir relaciones no presentes.

Adicional, la calidad de la estructuración depende tanto del contexto proporcionado al modelo como del diseño del *prompt* utilizado. Si tenemos variaciones en la forma en que se formula la instrucción pueden influir significativamente en el tipo de respuesta generada, si es acertada o no, así como en el nivel de detalle o precisión de la información extraída. Por lo anterior, el desempeño del sistema no depende únicamente del modelo que estamos utilizando, sino también de la claridad, especificaciones y consistencia de las indicaciones dadas.

Continuando con lo anterior, el tipo de documentos también representan un desafío. Es decir, si tenemos diferencias en el tipo de lenguaje, la forma en que esta escrito, las referencias que tenemos, el tipo de ortografía o incluso si tenemos fragmentos incompletos podemos afectar la interpretación que tendremos de los textos. En consecuencia, los resultados pueden presentar inconsistencias cuando el texto carece de suficiente contexto explícito.

Por lo anterior, debemos tomar en cuenta que la información generada debe considerarse como un apoyo al análisis histórico más no como un reemplazo de los especialistas que podemos utilizar en este tipo de lecturas. Es posible seguir desarrollando el *prompt* de acuerdo a los textos a los que nos enfrentamos y teniendo en cuenta que el modelo funciona como una herramienta que facilita la organización y exploración del contenido, pero la validación final requiere necesariamente de juicio experto.

8. Conclusiones

El proyecto tiene como objetivo desarrollar un sistema capaz de transformar colecciones extensas de textos en información estructurada que facilitará su consulta y análisis, concretámente de realizar reconocimiento de entidades nombradas (NER). Esto se realizó a partir del uso de modelos de lenguaje de gran escala, logrando automatizar la lectura y organización inicial del contenido, permitiendo identificar temas, relaciones y categorías sin necesidad de una revisión manual completa.

Esto fue posible con la segmentación de documentos, generación de respuestas guiadas por *promts* y una integración de los resultados obtenidos, llegando así a las categorías estructuradas.

Los resultados muestran que los modelos de gran escala constituyen una herramienta útil para el análisis de texto, particularmente en contextos donde el volumen de información dificulta un análisis sencillo. El modelo nos permite realizar una primera estructura permitiendo interpretar el contenido de una manera más sencilla, reduciendo considerablemente el tiempo necesario para explorar los documentos y facilitando la localización de información.

No obstante, debemos tener en cuenta que el sistema no sustituye la interpretación experta ya que los modelos de lenguaje pueden producir asociaciones incorrectas o conclusiones no presentes explícitamente en el texto. Por lo que la revisión por parte del especialista resulta fundamental para validar la coherencia histórica y semántica de los resultados. En este sentido, el sistema funciona como una herramienta de apoyo a la investigación, más no como un mecanismo autónomo de interpretación.

También se observó que el desempeño del modelo depende significativamente del diseño del *prompt* y del contexto proporcionado. Incluso pequeñas variaciones en las instrucciones pueden modificar la forma en que el modelo organiza la información, lo que nos hace recordar que la calidad del resultado no depende únicamente del modelo, sino también de la interacción que tenemos con las instrucciones por lo que no solo es importante el código generado para utilizar el modelo, sino el diseño y calidad que otorgamos al *prompt*.

Finalmente, el trabajo demuestra que la aplicación de técnicas de ciencia de datos y modelos de lenguaje puede integrarse en distintas áreas como el análisis histórico. La automatización de la lectura inicial nos permite el ahorro de tiempo pero también lograr que el enfoque del trabajo del especialista sea en una interpretación más profunda, ya que el sistema facilita la exploración de grandes volúmenes de información. Como trabajo futuro, el sistema podría ampliarse para incorporar validaciones automáticas adicionales y mejorar la consistencia de la extracción de información, así como un desarrollo del *prompt* que sea aplicable en más circunstancias.

Bibliografía

[1] Howard F. Cline. The relaciones geográficas of the spanish indies, 1577–1648. In Howard F. Cline, editor, *Handbook of Middle American Indians, Volume 12: Guide to Ethnohistorical Sources*, pages 183–242. University of Texas Press, Austin, 1972.

[2] René Acuña. *Relaciones Geográficas del siglo XVI.* Universidad Nacional Autónoma de México, México, 1982.

[3] Mercedes De la Garza, editor. *Relaciones histórico-geográficas de la gobernación de Yucatán.* Universidad Nacional Autónoma de México, México, 1983.

[4] Daniel Jurafsky and James H. Martin. *Speech and Language Processing.* Stanford University, 3 edition, 2023. Draft.

[5] Marti A. Hearst. Texttiling: Segmenting text into multi-paragraph subtopic passages. *Computational Linguistics*, 23(1):33–64, 1997.

[6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[7] Chris Biemann. Ontology learning from text: A survey of methods. *LDV Forum*, 20(2):75–93, 2005.

9. Repositorio

La información relacionada a este proyecto se puede encontrar en el siguiente repositorio.

https://github.com/ximenapaz22/Analisis_textos_LLM