Análisis de Texto con Modelos de Lenguaje

Instituto Tecnológico Autónomo de México

Mestría en Ciencia de Datos

Estancia de Investigación

Claudia Ximena Paz Cendejas
214570

Índice

1. Introducción **3**

1.1. Descripción del problema 3

1.2. Enfoque de Ciencia de Datos al problema 3

2. Objetivos **4**

3. Datos **5**

3.1. Recopilación de Datos 5

3.2. Tratamiento de los Datos 5

4. Modelo **6**

4.1. Metodología 6

4.2. Desarrollo 7

4.3. Resultados del modelo 7

4.4. Consulta de la información 8

5. Evaluación de Resultados **9**

6. Mejoras al modelo **10**

7. Conclusiones **11**

8. Bibliografía **12**

9. Repositorio **13**

1. Introducción

1.1. Descripción del problema

Los textos históricos son considerados una parte fundamental para el entendimiento y desarrollo de la sociedad a lo largo de los años. Han contribuido a la comprensión de culturas y de desarrollos políticos y sociales, por lo que se consideran de gran importancia. Sin embargo, dentro de ellos también se encuentra un gran desafío, ya que la información contenida no siempre es clara ni precisa.

Estos documentos fueron creados con el fin de dejar un registro (ya fuera narrativo, administrativo o testimonial) que permitiera conocer y entender el pasado. Sin embargo, en su elaboración no se contempló su análisis futuro, y mucho menos su análisis computacional, por lo que presentan diversas dificultades estructurales y lingüísticas.

En relación con lo anterior, aparecen problemas en las referencias a personas, lugares e instituciones, las cuales no siempre son explícitas ni consistentes. Asimismo, es común encontrar variaciones ortográficas e incluso menciones que asumen conocimientos propios de la época. Esto provoca que la lectura y comprensión de los textos resulte compleja y que su análisis automatizado sea limitado.

Debido a estas características, la alternativa tradicional ha sido la lectura manual por parte de especialistas como historiadores. Aunque este método resulta viable, ya que permite una compresión profunda del contenido, pero requiere de un gran esfuerzo y tiempo, y más aún cuando hablamos de colecciones grandes de textos como son los textos históricos.

En consecuencia, aunque los textos históricos estén disponibles, su consulta y análisis continuan siendo procesos difíciles y lentos, siendo poco escalables y limitando así su aprovechamiento.

1.2. Enfoque de Ciencia de Datos al problema

Los textos históricos son un conjunto de datos no estructurados con un alto valor de información. Teniendo la ventaja de que los textos se encuentran ya digitalizados, aún nos enfrentamos a su contenido que permanece en lenguaje natural, lo que imposibilita su análisis directo.

Es importante tener en cuenta que la información se encuentra a lo largo de todo el texto, por lo que conceptos importantes como personas, lugares, culturas, costumbres, no se encuentran en un lugar específico y se requiere del contexto de todo el texto para entender a lo que se refieren. Adicional a esto, es importante mencionar que una misma palabra puede tener distintos significados y esto solo se puede comprender si tenemos el contexto completo de lo que estamos procesando.

Es por esto que, no podemos realizar simplemente consultas ni extraer información de los textos sin un proceso previo de estructuración de los datos. Se requiere de un proceso que permita extraer información relevante, tener categorías principales que ayuden a un mejor entendimiento del contenido de los textos logrando así que un corpus se convierta en un recurso analizable.

2. Objetivos

Es ante esta necesidad, que se busca desarrollar un modelo que nos permita tener un mejor entendimiento de los textos evitando la lectura manual de estos, proponiendo una solución automatizada que permita procesar grandes colecciones de textos de una manera eficiente.

La idea del principal es utilizar modelos de lenguaje para así transformar el contenido de los textos en una estructura organizada de información que permita su explicación, consulta y análisis automatizando. Logrando así una consulta más sencilla de los textos y el conocimiento general de la información contenida en ellos. Con esto tendremos la posibilidad de convertir los textos complejos en una estructura más clara y fácil de consultar, facilitando su uso y exploración para diferentes análisis.

Al automatizar este proceso, no solo vamos a reducir el tiempo que se requiere para analizar los documentos, sino que también podremos realizar consultas más rápidas y sencillas entre las grandes cantidades de texto, permitiendo extraer información relevante y de ser necesario sabiendo que documento es el más adecuado a consultar para análisis más sofisticados.

El modelo propuesto tiene como objetivo transformar textos históricos en una representación estructurada de información. Para ello, se diseñó un proceso compuesto por varias etapas, desde la preparación de los documentos hasta la construcción de una estructura de conocimiento que se pueda consultar.

3. Datos

3.1. Recopilación de Datos

La recopilación de datos se hizo en conjunto con el doctor Diego, quien proporcionó textos históricos digitalizados que conforman el corpus de estudio.

Estos textos corresponden a Relaciones Geográficas elaboradas en el sigo XVI por orden de la Corona española. Fueron escritos como respuestas a un cuestionario oficial distribuido a autoridades locales (gobernadores, virreyes, etc) con el objetivo de recopilar información entre los territorios de la Nueva España.

En el cuestionario se solicitó información detallada sobre diversos aspectos. Comenzando con localización geográfica, distancias, características climáticas, territoriales y de recursos. Y abarcando datos sociales y culturales como lo son lenguas habladas, organización política, costumbres, vestimentas, alimentación, religiones, etc.

Como consecuencia, tenemos un corpus con documentos muy extensos, sin ninguna estructura y teniendo variación entre las respuestas, desde longitud hasta el tipo de redacción. Es por esto que este corpus es adecuado para la aplicación de modelos que busquen organizar y facilitar la consulta de la información contenida.

3.2. Tratamiento de los Datos

Inicialmente se realizó un preprocesamiento básico de los documentos con el objetivo de facilitar su análisis. En esta etapa se eliminaron elementos no textuales, encabezados repetitivos y caracteres producto de la digitalización, además de normalizar el formato del texto.

Debido a la longitud de los textos y a las limitaciones de procesamiento, los documentos fueron segmentados en fragmentos de menor tamaño, permitiendo su análisis individual sin perder el contexto general.

En este proceso de segmentación (chunking) cada texto fue dividido en fragmentos de tamaño controlado, menor a 1,500 caracteres obteniendo así textos divididos entre 168 y 471 chunks. El factor más importante en esta división es que se busco que cada segmento mantuviera coherencia semántica suficiente para su interpretación individual. Así mismo, se utilizó overlap con el objetivo de conservar el contexto entre secciones y evitar la pérdida de referencias mencionadas en distintos párrafos.

Cada fragmento fue procesado de manera independiente por el modelo de lenguaje para la extracción de entidades y relaciones. Posteriormente, los resultados obtenidos se estructuraron de manera global, unificando las entidades repetidas en una sola.

Con este tratamiento, fue posible adaptar y trabajar con documentos extensos manteniendo el contexto necesario para la comprensión de los textos.

4. Modelo

Con el fin de sistematizar el análisis de los documentos históricos, se implementó un modelo compuesto por diversas etapas de procesamiento. Este flujo metodológico permite organizar la información extraída y facilitar su posterior análisis. La Figura 1 resume el procedimiento general.

4.1. Metodología

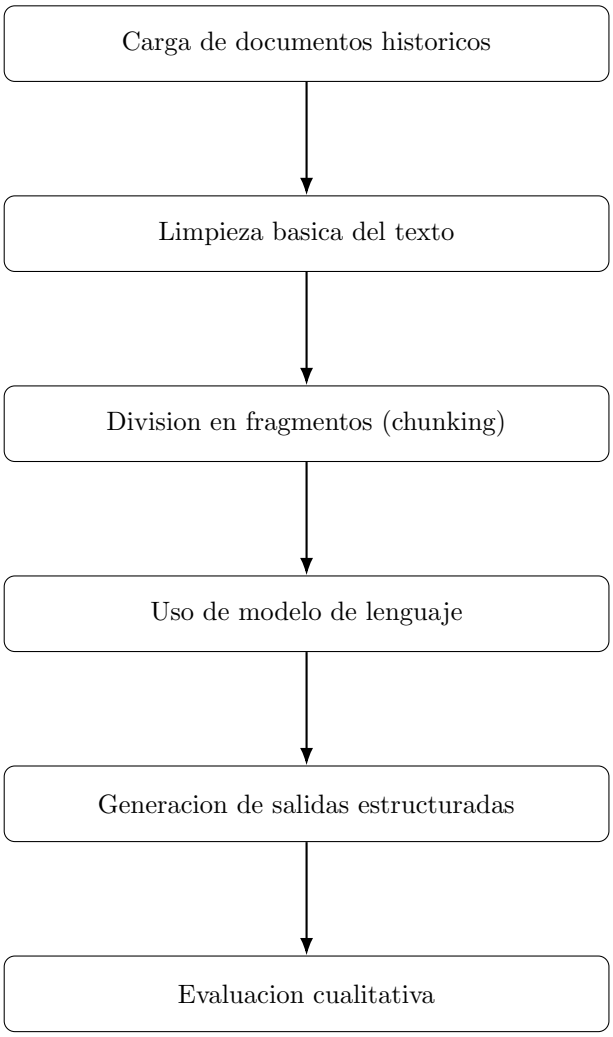

Figura 1: Flujo metodológico del sistema

4.2. Desarrollo

Para lograr organizar e identificar la información relevante dentro de los textos, se emplearon modelos de lenguaje de gran escala (LLM). Esta solución fue propuesta debido a la información con la que contamos y a que los métodos tradicionales de análisis (como clustering) resultaron limitados, pues dependían de formas específicas de escritura y evitando así que se logrará captar adecuadamente el significado del contenido.

Con estos modelos logramos no solo identificar palabras, sino analizar el contexto y la relación entre ellas, obteniendo así de una manera más sencilla y acertada el significado y relación, siendo particularmente útil en la identificación de una misma palabras con distintos significados como se presenta muy comúnmente en textos históricos.

Estos modelos no solo fueron adecuados por el lenguaje en el que estábamos tratando, sino también nos permitieron trabajar con grandes volúmenes de información de una manera automatizada, logrando que los textos fueran procesados de manera consistente pudiendo comparar entre los distintos archivos con los que contamos y evitando así la pérdida de contexto e información.

Como parte del desarrollo y utilización de los modelos de lenguaje de gran escala, debemos considerar el prompt siendo este la guía principal que nos ayuda a una correcta orientación, interpretación y respuesta que buscamos.

Aquí es donde establecemos el contexto de lo que estamos haciendo, el rol que estamos esperando del modelo (que es y como debe actuar) y con más detalle la salida que estamos esperando y así tener una correcta categorización del texto que es lo que estamos buscando.

Es muy importante el detalle que demos al prompt, pues muchas veces si nuestras instrucciones no son del todo claras o tienen muy poco detalle, pueden provocar respuestas incompletas o incluso erroneas a lo que estamos buscando. Por lo que en el desarrollo se realizaron distintos experimentos y ajustes en el prompt, modificando la forma en que solicitamos la información, en la que el modelo debía actuar, indicando a detalle quién es y que hace y restringiendo el formato y las respuestas que queremos recibir. Fue así que logramos reducir inconsistencias en las respuestas y mejorar la categorización obtenida.

Por lo anterior, el diseño del prompt se entiende como una etapa crucial en el modelo, teniendo siempre en mente que el desempeño del modelo no depende únicamente de su capacidad, si no de la claridad y consistencia que proporcionemos.

4.3. Resultados del modelo

La información extraída fue organizada en una estructura que nos permitiera conocer las palabras relevantes en los distintos archivos, y ya que se contaba con el contexto y relación, fue posible unificar distintas menciones que hacían referencia a una misma entidad, reduciendo la duplicidad provocada por variaciones ortográficas o denominaciones alternativas.

Asimismo, se establecieron relaciones entre las entidades identificadas, generando una red semántica que representa los vínculos presentes en el corpus. Esta representación permite consultar el contenido

de los textos sin necesidad de revisar manualmente cada documento.

4.4. Consulta de la información

Con esta estructura, es posible realizar consultas sobre el corpus, localizar información relevante e identificar conexiones entre elementos históricos. De esta forma, es posible tener una herramienta que nos apoye al análisis de documentos, facilitando la exploración del contenido.

La idea principal de las consultas es que el modelo haya logrado identificar adecuadamente una categoría para las palabras importantes, logrando así tener un diccionario de fácil acceso para cada palabra y logrando identificar temas importantes que ocurran en cada uno de los textos.

```
=== RESUMEN DE LA ONTOLOGÍA ===

Total de categorías: 40

- actividad_economica: 6 conceptos
- animal: 2 conceptos
- autor: 2 conceptos
- autoridad: 23 conceptos
- cargo: 9 conceptos
- costumbre: 39 conceptos
- cultivo: 6 conceptos
- documento: 6 conceptos
- especie: 2 conceptos
- event_historico: 1 conceptos
- evento_historico: 5 conceptos
- familia: 2 conceptos
- fruta: 10 conceptos
- grupo_social: 17 conceptos
- institucion_colonial: 38 conceptos
- legumbre: 1 conceptos
- lengua: 1 conceptos
- lengua_materna: 2 conceptos
- lenguaje: 1 conceptos
- linaje: 1 conceptos
- lugar: 274 conceptos
```

Figura 2: Ejemplo de categorías obtenidas

5. Evaluación de Resultados

Dado que el corpus corresponde a textos históricos, su interpretación y resultado de los conceptos obtenidos no puede verificarse únicamente mediante métricas, ya que el sentido de los términos depende de usos lingüísticos propios de la época y de su contexto cultural.

Por esta razón, los resultados generados por los modelos de lenguaje fueron revisados de manera cualitativa: El historiador evaluó coherencia entre las agrupaciones y relaciones encontradas, así como la interpretación general del contenido, verificando si las categorías producidas por el modelo correspondían con el significado histórico esperado. Con esta revisión fue posible validar si la información organizada por el sistema resultaba comprensible y útil desde una perspectiva disciplinaria.

Por lo que la evaluación combinó el procesamiento automatizado con la validación de un experto de dominio, asegurando que los resultados no solo fueran técnicamente correctos, sino también interpretativamente adecuados para el estudio de los documentos históricos.

6. Mejoras al modelo

A pesar de los resultados obtenidos, el sistema presenta ciertas limitaciones. Los modelos de lenguaje pueden generar interpretaciones incorrectas cuando el contexto histórico es ambiguo o cuando la información no es explícita en el texto. En algunos casos, el modelo puede asociar entidades de manera errónea o inferir relaciones no presentes.

Adicional, la calidad de la estructuración depende tanto del contexto proporcionado al modelo como del diseño del prompt utilizado. Si tenemos variaciones en la forma en que se formula la instrucción pueden influir significativamente en el tipo de respuesta generada, si es acertada o no, así como en el nivel de detalle o precisión de la información extraída. Por lo anterior, el desempeño del sistema no depende únicamente del modelo que estamos utilizando, sino también de la claridad, especificaciones y consistencia de las indicaciones dadas.

Continuando con lo anterior, el tipo de documentos también representan un desafío. Es decir, si tenemos diferencias en el tipo de lenguaje, la forma en que esta escrito, las referencias que tenemos, el tipo de ortografía o incluso si tenemos fragmentos incompletos podemos afectar la interpretación que tendremos de los textos. En consecuencia, los resultados pueden presentar inconsistencias cuando el texto carece de suficiente contexto explícito.

Por lo anterior, debemos tomar en cuenta que la información generada debe considerarse como un apoyo al análisis histórico más no como un reemplazo de los especialistas que podemos utilizar en este tipo de lecturas. Es posible seguir desarrollando el prompt de acuerdo a los textos a los que nos enfrentamos y teniendo en cuenta que el modelo funciona como una herramienta que facilita la organización y exploración del contenido, pero la validación final requiere necesariamente de juicio experto.

7. Conclusiones

El proyecto tiene como objetivo desarrollar un sistema capaz de transformar colecciones extensas de textos en información estructurada que facilitara su consulta y análisis. Esto se realizó a partir del uso de modelos de lenguaje de gran escala, logrando automatizar la lectura y organización inicial del contenido, permitiendo identificar temas, relaciones y categorías sin necesidad de una revisión manual completa.

Esto fue posible con la segmentación de documentos, generación de respuestas guiadas por promts y una integración de los resultados obtenidos, llegando así a las categorías estructuradas.

Los resultados muestran que los modelos de gran escala constituyen una herramienta útil para el análisis de texto, particularmente en contextos donde el volumen de información dificulta un análisis sencillo. El modelos nos permite realizar una primera estructura permitiendo interpretar el contenido de una manera más sencilla, reduciendo considerablemente el tiempo necesario para explorar los documentos y facilitando la localización de información.

No obstante, debemos tener en cuenta que el sistema no sustituye la interpretación experta ya que los modelos de lenguaje pueden producir asociaciones incorrectas o conclusiones no presentes explícitamente en el texto. Por lo que la revisión por parte del especialista resulta fundamental para validar la coherencia histórica y semántica de los resultados. En este sentido, el sistema funciona como una herramienta de apoyo a la investigación, más no como un mecanismo autónomo de interpretación.

También se observó que el desempeño del modelo depende significativamente del diseño del prompt y del contexto proporcionado. Incluso pequeñas variaciones en las instrucciones pueden modificar la forma en que el modelo organiza la información, lo que nos hace recordar que la calidad del resultado no depende únicamente del modelo, sino también de la interacción que tenemos con las instrucciones por lo que no solo es importante el código generado para utilizar el modelo, sino el diseño y calidad que otorgamos al prompt.

Finalmente, el trabajo demuestra que la aplicación de técnicas de ciencia de datos y modelos de lenguaje puede integrarse en distintas áreas como el análisis histórico. La automatización de la lectura inicial nos permite el ahorro de tiempo pero también lograr que el enfoque del trabajo del especialista sea en una interpretación más profunda, ya que el sistema facilita la exploración de grandes volúmenes de información. Como trabajo futuro, el sistema podría ampliarse para incorporar validaciones automáticas adicionales y mejorar la consistencia de la extracción de información, así como un desarrollo del prompt que sea aplicable en más circunstancias.

8. Bibliografía

Biemann, C. (2005). Ontology learning from text: A survey of methods. *LDV Forum, 20*(2), 75–93.

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., et al. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems, 33*, 1877–1901.

Diego. (2024). *Análisis de textos históricos mediante modelos de lenguaje*. Documento académico no publicado.

Material de práctica. (2024a). *Búsqueda vectorial con ChromaDB*. Notebook de Python (.ipynb).

OpenAI. (2023). *GPT models documentation*. Disponible en: https://platform.openai.com/docs

Ollama. (2024). *Ollama: Run large language models locally*. Disponible en: https://ollama.com

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems, 30*.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, 4171–4186.

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. En *Proceedings of the International Conference on Learning Representations (ICLR)*.

Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing* (3rd ed., draft). Stanford University. Disponible en: https://web.stanford.edu/ jurafsky/slp3/

Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., et al. (2021). On the opportunities and risks of foundation models.

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

9. Repositorio

La información relacionada a este proyecto se puede encontrar en el siguiente repositorio.

https://github.com/ximenapaz22/Analisis_textos_LLM